STUDI KASUS 01 | BIG DATA ANALYTICS

Retail Sales Analytics

Pandas & SQL / PySpark / Parquet / PostgreSQL 15 / Matplotlib

Disusun dari eksekusi aktual: 21-10-2026 14:01 WIB

Ringkasan proyek

Pipeline memproses 100.000 transaksi sintetis, dengan 551.507 unit dan penjualan bersih Rp 54.856.691.900,00. Semua tahap inti dijalankan dan hasil penyimpanan direkonsiliasi.

Indikator	Hasil
Baris / kolom sumber	100.000 / 12
Rentang tanggal	2024-01-01 sampai 2026-09-30
Gross sales	Rp 58.074.226.000,00
Net sales	Rp 54.856.691.900,00
Rata-rata per transaksi	Rp 548.566,92

Rumusan masalah

- Bagaimana tren penjualan bersih bulanan?

- Cabang dan kategori mana yang paling berkontribusi?

- Metode pembayaran mana yang paling sering digunakan?

Data ini sintetis. Hasil merupakan demonstrasi analitik dan tidak mewakili kondisi pasar retail sebenarnya. Nama, NIM, dan anggota kelompok diisi pada berkas identitas sebelum dikumpulkan.

01 / Data dan metode

Sumber data: repositori ruhyana/big-data-sales-analytics. Satu baris merupakan satu catatan transaksi produk. ID transaksi unik; tidak tersedia ID pelanggan. Rata-rata dihitung per catatan transaksi, bukan per pelanggan.

Alur: CSV -> profiling Pandas dan SQL sumber (SQLite) -> transformasi PySpark -> Parquet Snappy dan PostgreSQL 15 -> rekonsiliasi -> Matplotlib dan rekomendasi. SQLite hanya untuk profiling sumber; PostgreSQL tetap menjadi storage wajib.

Kelompok kolom	Isi
Identitas dan waktu	transaction_id, transaction_date
Dimensi bisnis	branch, category, product_name, payment_method, customer_segment
Kuantitas dan harga	quantity, unit_price, discount_rate
Nilai penjualan sumber	gross_sales, net_sales

Transformasi dan metrik

- Cast tanggal, ID, kuantitas, harga, dan diskon dengan skema eksplisit; normalisasi whitespace dimensi.

- Hitung gross = quantity x unit_price; net = gross x (1-discount_rate); discount_amount = gross-net.

- Turunkan month dan basket_band: High >= Rp1 juta; Medium >= Rp500 ribu; Low di bawah Rp500 ribu.

- Agregasikan transaksi, unit, dan net sales menurut bulan, cabang, kategori, serta metode pembayaran.

Penanganan nilai kosong dan invalid

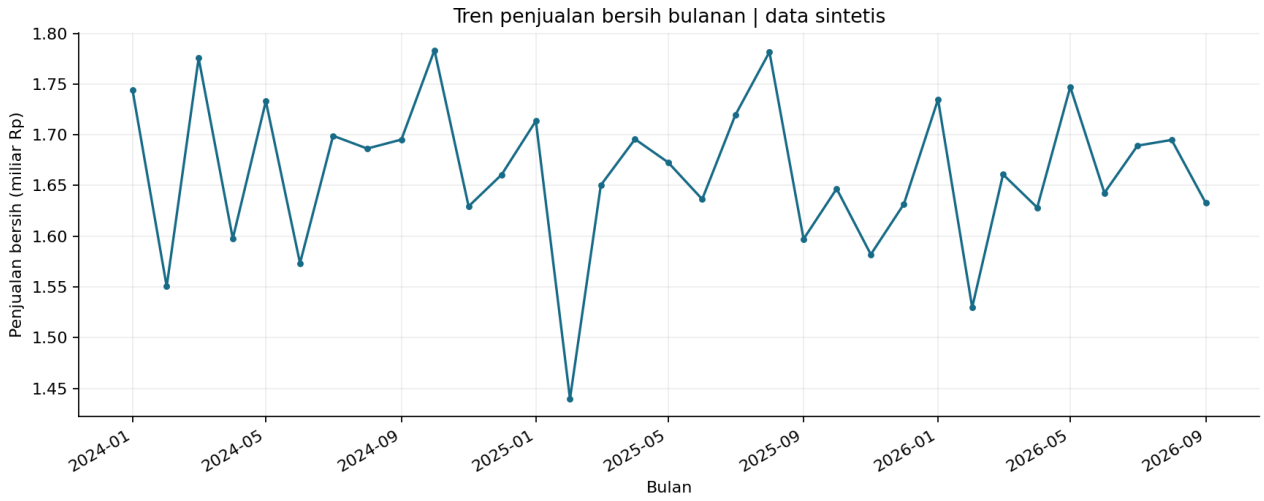
Baris wajib kosong/invalid, tanggal tidak valid, kuantitas tidak positif atau pecahan, harga negatif, diskon di luar 0-1, serta formula salah dikarantina. Semua kemunculan ID duplikat ditolak. Nilai uang tidak diimputasi. Sumber utama sudah bersih; fixture rusak menguji perilaku penolakan.

Uang menggunakan Decimal di Spark dan NUMERIC di PostgreSQL. Semua rekonsiliasi uang memakai toleransi absolut Rp0,02. Tidak digunakan toleransi relatif.

Pada Windows lab, hasil Spark dikumpulkan ke driver lalu ditulis melalui Arrow. Parquet dibaca ulang oleh Pandas dan Spark. Untuk skala produksi, gunakan penulisan Spark terdistribusi di Linux/cluster.

02 / Tren penjualan bulanan

Puncak penjualan bulanan terjadi pada 2024-10, sebesar Rp 1.783.478.200,00 dari 3.158 transaksi.



Total diskon pada periode pengamatan adalah Rp 3.217.534.100,00. Penjualan bersih sudah memperhitungkan diskon, tetapi belum mengurangi harga pokok maupun biaya operasional.

Interpretasi

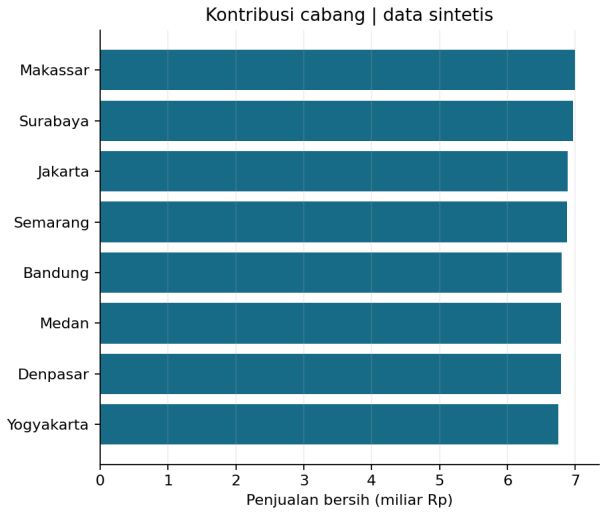
Puncak bulanan menunjukkan periode dengan nilai penjualan terbesar pada data yang diamati. Angka ini tidak membuktikan pengaruh kampanye, hari besar, atau penyebab tertentu karena variabel tersebut tidak tersedia.

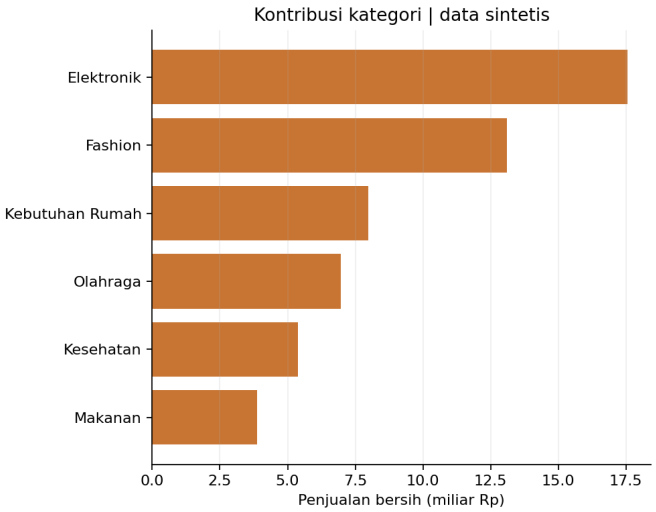
Rentang data 2024-01-01 sampai 2026-09-30. Perbandingan tahunan wajib memakai cakupan bulan yang sebanding. Satu bulan puncak tidak cukup untuk menyatakan musim berulang.

Implikasi

Gunakan tren bulanan untuk merencanakan evaluasi kampanye. Jangan menyimpulkan pola musiman berulang dari satu bulan puncak atau membandingkan tahun parsial dengan tahun penuh.

03 / Cabang dan kategori





Makassar menghasilkan penjualan bersih terbesar, Rp 6.996.060.300,00, atau 12,75% dari total.

Kategori Elektronik menyumbang Rp 17.545.252.850,00 atau 31,98% dari total pendapatan bersih.

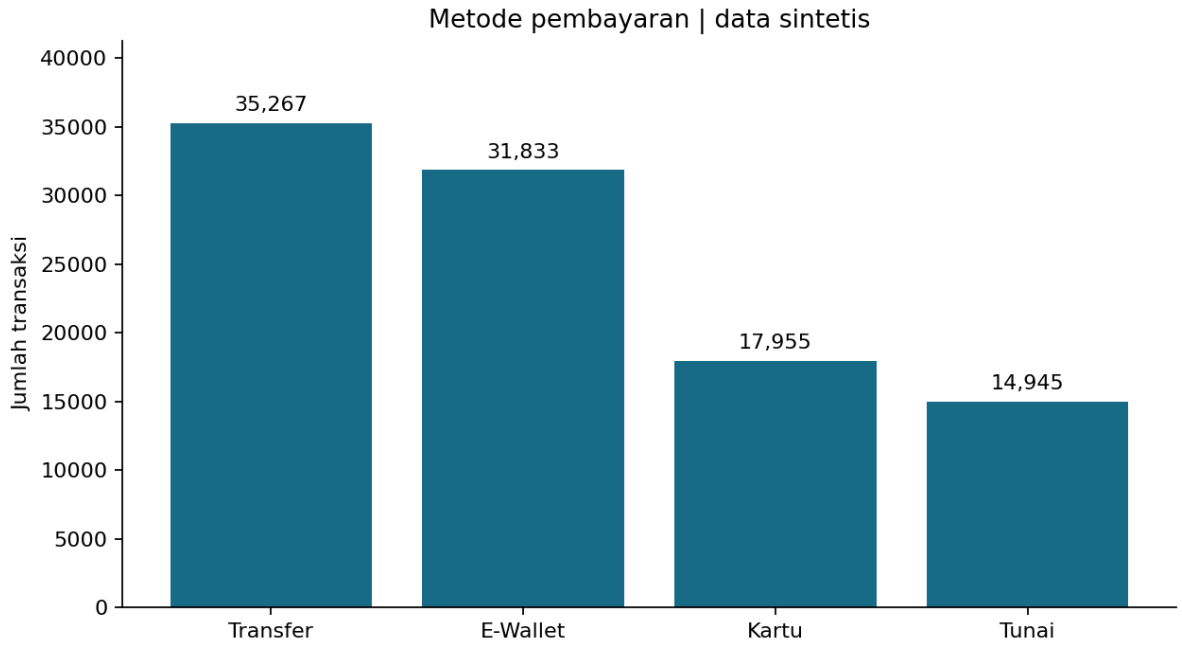
Rekomendasi berbasis kontribusi

Gunakan Makassar sebagai titik awal kajian praktik operasional cabang. Bandingkan jumlah transaksi dan nilai rata-rata sebelum menyalin strategi; penjualan bukan laba.

Prioritaskan tinjauan ketersediaan produk Elektronik karena kontribusinya besar. Keputusan pembelian stok perlu data margin, stok, lead time, dan permintaan yang belum tersedia.

Istilah teratas pada grafik mengacu pada nilai penjualan bersih. Peringkat berdasarkan jumlah unit atau laba dapat berbeda. Data margin belum tersedia, sehingga laporan tidak menyebut cabang atau kategori paling menguntungkan.

04 / Pembayaran dan keputusan bisnis



Metode Transfer digunakan pada 35.267 transaksi (35,27%).

Pastikan kanal pembayaran Transfer tetap mudah digunakan dan dipantau. Evaluasi biaya, tingkat gagal, dan waktu settlement sebelum menentukan promosi pembayaran.

Prioritas tindak lanjut

Prioritas	Tindakan	Data tambahan / ukuran keberhasilan
1	Tinjau stok kategori kontributor utama	Stockout rate, margin, lead time, penjualan hilang
2	Bandingkan praktik cabang	Jumlah transaksi, nilai rata-rata, biaya operasional
3	Pantau kanal pembayaran populer	Failure rate, biaya transaksi, settlement
4	Evaluasi kampanye per bulan	Kalender promo dan perbandingan periode setara

05 / Validasi dan integritas storage

Pemeriksaan	Hasil
rows_100000	PASS
at_least_10_columns	PASS
unique_ids	PASS
no_nulls	PASS
valid_dates	PASS
nonempty_dimensions	PASS
finite_numbers	PASS
positive_integer_quantity	PASS
nonnegative_price	PASS
discount_range	PASS
gross_formula	PASS
net_formula	PASS

Spark: 100.000 input; 100.000 diterima; 0 invalid; 0 duplikat. Agregat bulanan cocok dengan data acuan dan SQL sumber.

Parquet: round-trip seluruh field cocok; Spark membaca 100.000 baris. PostgreSQL: 100.000 baris, field sumber cocok seluruhnya, empat agregasi cocok dengan perhitungan SQL, dan formula mismatch = 0.

Uji input rusak: 9 baris -> 1 diterima, 6 invalid, dan 2 duplikat. Spasi dinormalisasi dan selisih Rp1 ditolak.

Pemuatan PostgreSQL atomik: penggantian isi tabel proyek dan validasi dilakukan sebelum commit. Kegagalan menyebabkan rollback dan audit FAILED. Pengulangan tidak menambah duplikat. Bukti ada pada output/validation/.

Versi server: PostgreSQL 15.19, compiled by Visual C++ build 1944, 64-bit

06 / Uji performa aktual

Tiga ulangan per skala; tabel berisi median detik. Spark local[2], driver 2 GiB. Satu warmup JVM dikecualikan. Kedua engine memakai writer Arrow dan reader Pandas yang sama untuk storage.

Engine / baris	CSV	Transform	Collect	Tulis	Baca ulang	Total
pandas / 10.000	0.010	0.023	0.001	0.010	0.010	0.055
pandas / 100.000	0.078	0.203	0.022	0.062	0.029	0.380
pandas / 1.000.000	0.632	2.117	0.227	0.562	0.216	3.724
spark / 10.000	0.163	0.256	0.092	0.011	0.010	0.531
spark / 100.000	0.259	0.339	0.603	0.080	0.029	1.326
spark / 1.000.000	1.273	1.103	6.165	0.749	0.216	9.552

Transformasi mencakup tanggal, net sales, dan agregasi bulan-cabang-kategori. Spark dipaksa melakukan count/collect agar waktu mencakup pekerjaan nyata. Collect ke driver diukur terpisah. Total adalah median total tiap ulangan dan dapat berbeda dari penjumlahan median fase.

10k memakai baris pertama; 100k sumber asli; 1 juta mengulang sumber dengan ID baru. Data skala besar tidak menambah observasi bisnis independen. Cache OS tidak dibersihkan dan mesin dipakai bersama proses lain.

Interpretasi performa

Biaya JVM, scheduling, serialisasi, dan collect dapat mendominasi data kecil. Pengujian ini menilai alur lab pada satu komputer dan tidak membuktikan throughput cluster. Spark dipakai untuk mempelajari pola pemrosesan terdistribusi, bukan untuk menjamin lebih cepat pada 100 ribu baris.

Runtime: Windows-11-10.0.26300-SP0; Python 3.12.14; CPU logis 16; Spark 3.5.3.

Data semua ulangan: output/performance_runs.csv. Protokol dan versi: output/performance_method.json. Waktu PostgreSQL dan audit disimpan terpisah dari benchmark analitik.

07 / Keterbatasan dan reproduksi

- Seluruh data sintetis: hasil menguji alur analitik dan tidak menggambarkan pasar retail Indonesia yang sebenarnya.

- Rentang observasi 2024-01-01 sampai 2026-09-30; perbandingan tahun harus memperhatikan cakupan bulan yang berbeda.

- Tidak tersedia harga pokok, margin, persediaan, target, atau identitas pelanggan. Penjualan tertinggi tidak berarti laba tertinggi dan penyebab perbedaan belum dapat dibuktikan.

- Spark berjalan pada satu laptop dengan dua thread. Pengumpulan ke driver dan penulisan Arrow sesuai lab, tetapi membatasi skala memori. Produksi besar memerlukan penulisan Spark terdistribusi.

- Uji 1 juta baris mengulang sumber dengan ID baru; tidak menambah keragaman bisnis. Benchmark mencakup cache OS yang tidak dibersihkan dan proses lain pada komputer.

Cara menjalankan

- Gunakan Python 3.12, Java 17, dan PostgreSQL 15. Pasang requirements.txt dalam virtual environment.

- Jalankan tools/start_lab.ps1 untuk database portabel di localhost, atau isi .env untuk database lab sendiri.

- Jalankan notebook 01_exploration, 02_pyspark_transform, dan 03_etl_validation secara berurutan.

- Alternatif: python run_pipeline.py. Kemudian python scripts/validate_outputs.py. Benchmark memiliki 3 ulangan pada 3 skala.

- Skrip ETL mengganti isi tabel sales_lab milik proyek. Gunakan database khusus, bukan database lain.

Berkas pengumpulan

Notebook dengan output eksekusi, data sumber, SQL, agregasi CSV/Parquet, tiga grafik PNG, validasi JSON/CSV, benchmark, laporan PDF/Markdown, dan outline presentasi. Checklist persyaratan ada di reports/checklist_rubrik.md.

Referensi dan asal data

Tugas_studi_kasus_big_data.pdf, halaman 2-4 dan 14-17. Repositori: https://github.com/ruhyana/big-data-sales-analytics. Commit dan hash sumber tercatat pada SOURCE_PROVENANCE.json dan output/runtime.json. Hasil dihitung ulang dari data; tidak disalin dari ringkasan README awal.